

Técnicas de machine learning em auxílio à missões de busca e salvamento para a Bacia de Campos

Victor Vinicius Araujo Ferreira^{1*}; Francisco Lledo dos Santos²

¹ Mestre. Rua Barão de Jaceguai, s/nº - Ponta da Armação; 24048-900, Niterói, Rio de Janeiro, Brasil.

² Universidade do Estado de Mato Grosso – PROFÁGUA - Doutor em Engenharia Elétrica – Professor Adjunto.
Av. Fernando Corrêa da Costa, nº 2367 - Boa Esperança; 78060-900 Cuiabá, MT, Brasil

*autor correspondente: victor.ocn@gmail.com

Técnicas de machine learning em auxílio à missões de busca e salvamento para a Bacia de Campos

Resumo

Missões de Busca e Salvamento no mar, ou “Search And Rescue” [SAR], apresentam grande desafio devido à extensão da costa brasileira e da complexidade da dinâmica dos oceanos. Diante disso, algumas técnicas e modelos computacionais podem ser utilizados para otimizar a delimitação da área de busca com maior precisão ou modelar a trajetória dos alvos na superfície do mar. Este trabalho busca analisar a viabilidade de utilização de técnicas de “Machine Learning” para aumentar a acurácia na determinação da trajetória de objetos na superfície do mar em casos de SAR. Foram selecionados dados de boias de deriva na área da Bacia de Campos e realizadas simulações de partículas na superfície do mar através de um modelo lagrangeano para simular a trajetória das mesmas. Diferentes técnicas de Machine Learning foram utilizadas considerando as trajetórias simuladas como variáveis preditoras e as trajetórias reais das boias como variável “target”. O modelo Random Forest apresentou os menores erros ao prever os dados de teste, seguido do modelo “Extreme Gradient Boosting” e da Rede Neural Multicamadas [MLP] proposta. Os resultados se apresentaram significantes, mostrando grande aderência entre os dados previstos e os observados.

Palavras-chave: SAR; deep learning; opendrift; random forest; redes neurais artificiais.

Introdução

O Brasil possui um extenso litoral e por consequência diversas atividades econômicas e recreativas estão ligadas ao mar. De acordo com os dados da Diretoria de Portos e Costas da Marinha do Brasil, nos últimos dez anos foram registrados por semana, em média, cerca de 5 vítimas fatais ou desaparecidas em casos de acidentes no mar (DPC, 2022).

A Marinha do Brasil é responsável pelas operações de Busca e Salvamento, ou “Search And Rescue” [SAR], em uma área que se estende por toda a costa brasileira até o meridiano de 10°W, abrangendo uma extensa área do Atlântico Sul (SALVAMAR BRASIL, 2020). Diante do desafio de cobrir uma área tão extensa, o planejamento de missões de Busca e Salvamento pode ser impreciso e demorado se todos os cálculos e representações gráficas forem efetuados à mão.

Portanto, diferentes modelos computacionais para descrever a dinâmica do ambiente marinho são utilizados, sendo possível duas abordagens distintas: a lagrangiana e a euleriana. Na abordagem euleriana a descrição do movimento do fluido é baseada em um referencial fixo no espaço, enquanto na abordagem lagrangiana, a descrição do fluido é baseada em um referencial que está se movendo como uma partícula de fluido infinitesimal. (Van Sebille et al., 2018). Os modelos lagrangianos rastreiam um conjunto de partículas traçadoras no tempo, a partir de uma fonte, e são importantes ferramentas para modelar o transporte de objetos flutuantes no mar (De Dominicis et al., 2016).

Para a simulação das trajetórias de objetos na superfície do mar, são necessários dados ambientais disponíveis em tempo real, tais como campos de vento e corrente oceânicas (Breivik e Allen, 2008). Frequentemente, as informações ambientais são fornecidas por modelos computacionais eulerianos de circulação, ondas e atmosféricos (Ličer et al., 2020).

Mesmo com a tecnologia dos modelos computacionais, diversos erros podem ser atribuídos aos cálculos em diferentes escalas. Aliado a isso, os modelos tradicionais tendem a um gasto computacional elevado. A fim de tentar minimizar esses erros e diminuir o esforço computacional, técnicas de “Machine Learning” [ML] tem sido utilizadas em conjunto com “ensemble” de modelos determinísticos para obter melhores resultados. As técnicas de ML podem usar diferentes métodos, desde uma simples regressão linear até complexas redes neurais artificiais em “Deep Learning”.

Diante disso, este trabalho buscou analisar a viabilidade de utilização de modelos de “Machine Learning” para determinar a trajetória de objetos na superfície do mar através de simulações com um modelo lagrangiano de partículas, a fim de auxiliar operações SAR.

Material e Métodos

O método proposto consistiu em comparar as observações das trajetórias de derivadores na Bacia de Campos e a posição de partículas simuladas por um modelo lagrangiano, utilizadas como variáveis preditoras em modelos de Machine Learning.

Área de Estudo

A Bacia de Campos é a principal bacia sedimentar “offshore” de exploração de petróleo do Brasil. Possui uma área aproximada de 100.000km² entre a Cadeia Vitória-Trindade e o Alto de Cabo Frio (Vianna et al, 1998). A Figura 1 mostra o mapa batimétrico da Bacia de Campos, sendo a região considerada neste estudo entre as latitudes 20°S e 24°S, e longitudes entre 36°W e 42°W.




Figura 1. Mapa batimétrico da Bacia de Campos
Fonte: Elaborado pelo autor com base em Smith (1997)

A principal corrente oceânica na dinâmica da região é a Corrente do Brasil [CB], caracterizada por um fluxo intenso para Sul próximo à margem continental, com altas temperaturas e salinidade, acompanhando a direção da quebra de plataforma (Godoi, 2005; Mano, 2007). Próximo a Cabo Frio e São Tomé, se desenvolvem meandros ciclônicos, podendo se tornar vórtices isolados que intensificam as velocidades de corrente e até mesmo inverter seu sentido (Lima, 1997; Calado, 2001).

Na parte mais interna da plataforma continental, a circulação oceânica é forçada pelo vento dominante (Castro, 1996). Durante o ano predominam ventos de E/NE gerados pelo Anticiclone Semipermanente do Atlântico Sul [ASAS]. No entanto, a passagem de frentes frias inverte progressivamente o sentido dos ventos, fluindo de W/SW. (Stech e Lorenzzetti, 1992). O período de maior passagem de frentes frias ocorre nos meses de agosto a novembro (Lemos e Calbete, 1996).

A região também é marcada pelo fenômeno de ressurgência, caracterizado pela intrusão de águas frias e ricas em nutrientes até a superfície devido ao regime de ventos, a mudança brusca da linha de costa e o gradiente topográfico (Rezende, 2003; Rodrigues e Lorenzzetti, 2001). A Figura 2 mostra algumas feições oceanográficas da região.

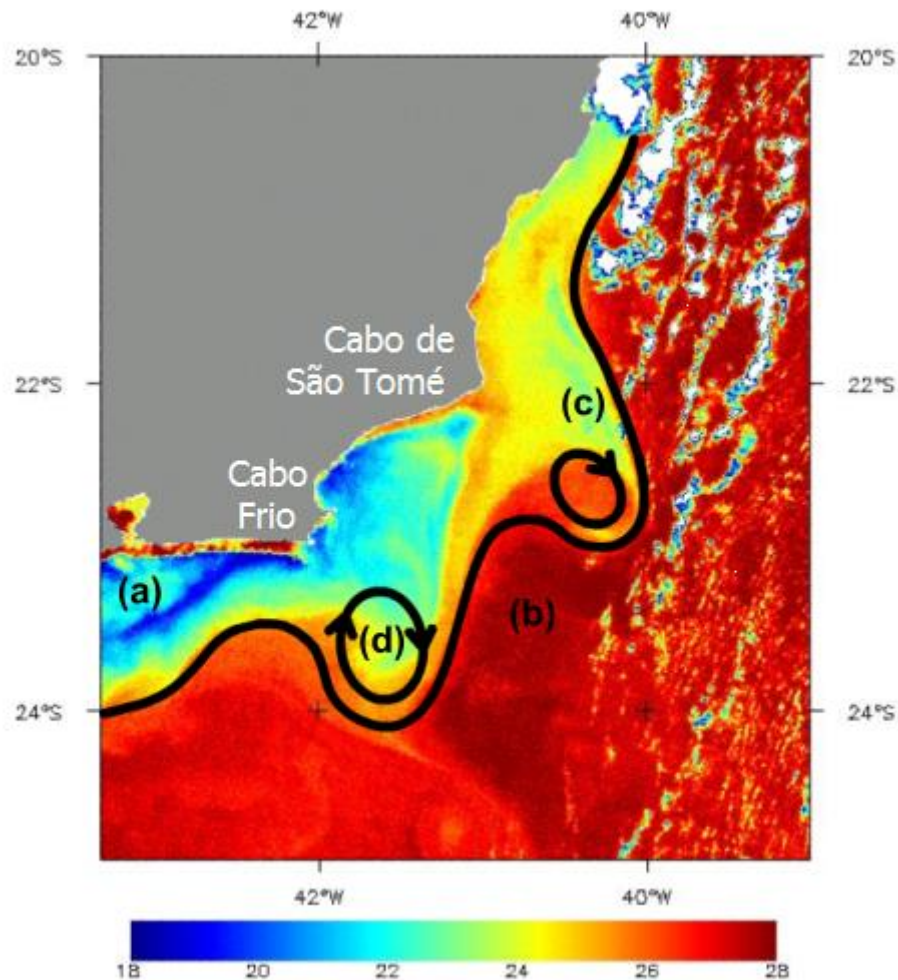


Figura 2. Mapa de Temperatura (°C) da Superfície do Mar [TSM] da Bacia de Campos

Fonte: Elaborado pelo autor com base em Silveira (2007)

Nota: (a) Parte interna da plataforma continental: fenômeno de ressurgência (temperaturas < 22°C); (b) Corrente do Brasil - em vermelho; (c) Vórtice de São Tomé; (d) Vórtice de Cabo Frio

O modelo de deriva Opendrift

O “OpenDrift” é um modelo de partículas lagrangeanas, “open source”, em linguagem “python”, desenvolvido pelo Instituto Meteorológico Norueguês (Dagestad *et al.*, 2018). O modelo simula o deslocamento de objetos, ou substâncias, na superfície do mar representado por um número de partículas sujeitas à ação dos ventos, correntes e ondas oceânicas. O sistema conta com diversos módulos, onde cada um deles é voltado para a discretização de uma família de partículas diferentes. O “Leeway” é o módulo de Busca e Salvamento baseado no modelo operacional do Instituto Meteorológico da Noruega, descrito por Breivik e Allen (2008). Ele possui uma lista de classes de objetos, cada um com suas propriedades específicas de deriva, baseadas em resultados empíricos. Para as simulações

foi escolhido o objeto do tipo “Person in water 3” [PIW3], que considera uma pessoa trajando um colete salva vidas, conforme demonstrado na Figura 3.




Figura 3. Representação de um objeto classe PIW3
Fonte: Elaborado pelo autor com base em Allen et al. (1999)

Para a simulação do deslocamento das partículas são necessárias informações de ventos e correntes oceânicas, em uma grade regular, com informações precisas em cada ponto e para cada instante de simulação. Diante disso, o Opendrift utiliza links de plataformas internacionais que disponibilizam gratuitamente resultados de modelos meteoceanográficos globais.

Um dos modelos hidrodinâmicos disponíveis é o “HYbrid Coordinate Ocean Model” [HYCOM] com assimilação de dados “Navy Coupled Ocean Data Assimilation” [NCODA], disponibilizado pela Marinha dos Estados Unidos (HYCOM, 2022). Outro modelo hidrodinâmico disponível é o Mercator, disponibilizado pela “Copernicus Marine Environment Monitoring Service” [CMEMS], um consórcio entre entidades da União Européia (COPERNICUS, 2022). Os resultados dos modelos HYCOM/NCODA e Mercator possuem resolução espacial de $1/12^\circ$. Já o modelo atmosférico mais utilizado é o Global Forecast System [GFS] desenvolvido pelo National Centers for Environmental Prediction [NCEP] da agência americana National Oceanic and Atmospheric Administration [NOAA]. O GFS possui resolução espacial de aproximadamente 50 km (GFS, 2011).

Boias de Deriva

As boias de deriva, ou derivadores, são instrumentos de medição de dados oceanográficos que são dispersos em pontos de interesse e, enquanto se deslocam sob influência dos ventos e correntes oceânicas, coletam dados da superfície do mar. Os dados e as coordenadas da posição dos derivadores são transmitidos, via satélite, para estações em terra em intervalos regulares.

O sistema de oceanografia operacional CORIOLIS (<https://www.coriolis.eu.org/>) disponibiliza gratuitamente dados de derivadores em todo o globo. O modelo de derivador escolhido foi o “Surface Velocity Program” [SVP]. A boia possui uma estrutura flutuante esférica com 35 centímetros de diâmetro e uma vela de arrasto (“drogue”) tipo “Holey Sock” de 15 metros de profundidade, conforme mostrado na Figura 4.




Figura 4. Esquema do derivador SVP

Fonte: Elaborado pelo autor com base em Copernicus Marine In Situ Tac (2020)

A vela de arrasto maximiza a ação das correntes oceânicas sobre o derivador, diminuindo a influência das ondas e do vento (Lumpkin et al., 2017). Sutherland et al. (2020) mostraram que os derivadores SVP possuem fator de influência do vento inferior a 1%, o que se assemelha com as características de uma pessoa na superfície do mar (PIW3).

Simulações de Trajetória

Dentre as boias disponíveis, foram selecionadas 13 derivadores SVP cuja trajetória representasse feições coerentes com a capacidade de solução matemática dos modelos hidrodinâmicos globais. Considerando a resolução de $1/12^\circ$ é esperado que certas feições regionais e de mesoescala, tais como vórtices e meandros, não sejam resolvidas com grande acurácia. A Tabela 1 mostra os derivadores selecionados, o início e o fim do período considerado para as simulações.

Tabela 1. Derivadores e períodos selecionados para a análise

Derivadores SVP	Início	Final
1501559	29 jun 2020 - 14h00min	18 jul 2020 - 20h00min
1501675	21 fev 2020 - 14h00min	16 mar 2020 - 01h00min
1501676	21 fev 2021 - 11h00min	27 fev 2021 - 00h00min
1601695	19 ago 2021 - 00h00min	26 ago 2021 - 00h00min
1701516	19 fev 2021 - 00h00min	03 mar 2021 - 00h00min
1701643	18 jan 2021 - 00h00min	26 jan 2021 - 00h00min
1701647	14 ago 2021 - 16h00min	22 ago 2021 - 21h00min
2301552	21 set 2021 - 13h00min	02 out 2021 - 14h00min
3100865	14 nov 2021 - 06h00min	17 nov 2021 - 19h00min
3101510	03 ago 2021 - 17h00min	22 ago 2021 - 15h00min
3101602	23 set 2021 - 02h00min	29 set 2021 - 06h00min
3301612	05 abr 2021 - 20h00min	16 abr 2021 - 08h00min
6202622	20 set 2021 - 20h00min	28 set 2021 - 06h00min

Fonte: Dados originais da pesquisa

Para cada derivador foram realizadas duas simulações com OpenDrift (módulo Leeway) cada uma utilizando um dos modelos hidrodinâmicos supracitados (HYCOM/NCODA + GFS e Mercator + GFS). Em cada simulação foram geradas 10 partículas virtuais, com coordenadas de lançamento igual ao ponto inicial do derivador e tempo de previsão correspondente ao final do período de análise respectivo a cada uma das boias.

Modelos Machine Learning

Diante disso, levantou-se a hipótese de que a partir das coordenadas das partículas simuladas com Opendrift, com ambos os modelos hidrodinâmicos, os modelos de Machine Learning poderiam prever as coordenadas da trajetória do derivador de forma mais precisa que as simulações isoladamente.

Foram realizados modelos de Machine Learning, com diferentes técnicas, para cada componente das coordenadas das partículas simuladas: longitude (x_{ij}) e latitude (y_{ij}), onde i é o modelo (HYCOM/NCODA = 0 e Mercator = 1) e j o número da partícula (0 a 9). A

fórmula também levou em consideração a variável prog (tempo de previsão em horas após o lançamento).

A fim de estabelecer uma referência da eficácia dos modelos, foi calculada a média da longitude e da latitude de todas simulações realizadas (x_{ij}, y_{ij}) para cada tempo da simulação (t_{ij}) . Espera-se que os modelos tenham erro inferior do que o método de referência.

O primeiro modelo a ser testado foi o Modelo de Regressão Linear [MRL], com a biblioteca lm do software R. Os resultados foram verificados pelo teste-F e teste-T durante o processo de “Stepwise” (Venables e Ripley, 2002) e o teste de Shapiro-Francia, com o algoritmo proposto por Royston (1993) que verifica a adequação dos resíduos dos modelos à curva Normal. Em caso de reprovação no último teste, a transformação de BOX-COX, proposta por Yeo e Johnson (2000), foi a alternativa encontrada, uma vez que os dados de entrada são números negativos.

Outro modelo utilizado foi o Random Forest [RF] com a biblioteca “caret” (método “rf”) do software R. O RF é um “ensemble” tipo “Bagging” baseado em árvore de decisão, ou seja, são gerados diversos modelos aleatórios de árvore de decisão que tentam prever a variável e “votam” no melhor resultado. Os dados foram separados em duas amostras: treino e teste. A amostra de treino consistiu em 80% dos dados e a de teste 20%. Foram utilizadas 100 árvores, permitindo árvores com profundidade de 1 a 10 níveis. O modelo foi treinado através da técnica de “cross-validation” tipo k-fold com $k=20$ e três repetições.

O terceiro modelo utilizado também é baseado em árvores de decisão, porém com a técnica de Boosting, no qual utiliza-se vários modelos sequenciais que tentam diminuir os resíduos do modelo anterior. Foi utilizado o algoritmo Extreme Gradient Boosting [XGB] da biblioteca “caret” (método “xgbTree”) do software R. Foram testadas 100 árvores com diferentes taxas de aprendizagem (0,1 e 0,3) e diferentes profundidades (2, 3 e 5) através da técnica de “Grid Search”. O dado foi treinado da mesma forma que o modelo anterior.

Por fim, foi rodado um modelo de Redes Neurais Multicamadas [RNM], ou “Multi-Layer Neural Networks” [MNN] com o pacote “neuralnet” do software R. Foram testadas diferentes arquiteturas de rede neural com objetivo de verificar a que realiza previsões mais assertivas. O modelo foi treinado com 80% dos dados e testado com os 20% restantes.

Após o treino de todos os modelos, foram geradas previsões com os dados de teste. Os modelos foram avaliados de forma qualitativa pela aderência dos valores preditos aos valores observados na amostra de teste. Também foram avaliados quantitativamente através do cálculo do “Mean Absolute Error” [MAE] e o “Root Mean Squared Error” [RMSE].

Resultados e Discussão

Derivadores vs. Simulações de trajetória com Opendrift

As simulações de partículas do Opendrift para cada derivador, considerando como entrada os resultados dos modelos hidrodinâmicos globais HYCOM e Mercator, estão dispostas no Apêndice A.

Notou-se que a deriva das partículas varia mais em diante de correntes mais fracas, e possui comportamento mais uniforme diante de correntes mais intensas, e.g. CB. Os resultados são coerentes com Bueno et al. (2021) que observaram resultados semelhantes diante de correntes oceânicas intensas. As partículas simuladas não são perfeitamente aderentes à trajetória do derivador, independente do modelo utilizado, o que reforça a necessidade de metodologias que consigam projetar a trajetória mais provável em casos de SAR. No entanto, as simulações se mostraram coerentes com o movimento real da boia.

Distribuição dos dados

A Figura 5 mostra o correlograma entre as variáveis simuladas (x_{ij} , y_{ij} e $prog$) e as coordenadas observadas (x e y).




Figura 5. Correlograma das variáveis preditoras utilizadas

Fonte. Resultados originais da pesquisa

Conforme esperado, as coordenadas verticais (x_{ij}) simuladas possuem grande correlação positiva (próximo de 1) com as coordenadas verticais (x) do derivador e entre elas. O mesmo ocorre com as coordenadas horizontais (y_{ij} e y). Já a variável $prog$ possui baixa correlação (próximo de zero) com todas as outras variáveis. Sua importância se dá na determinação do

estágio da simulação, pois quanto maior o tempo de simulação maior dispersão das partículas é esperado. As Figuras 6 e 7 mostram a dispersão das variáveis preditoras (x_{ij} e y_{ij}) e as coordenadas reais dos derivadores (x e y).




Figura 6. Gráfico boxplot das variáveis horizontais (longitude): x (variável resposta) e x_{ij} (variáveis preditoras)

Fonte. Resultados originais da pesquisa

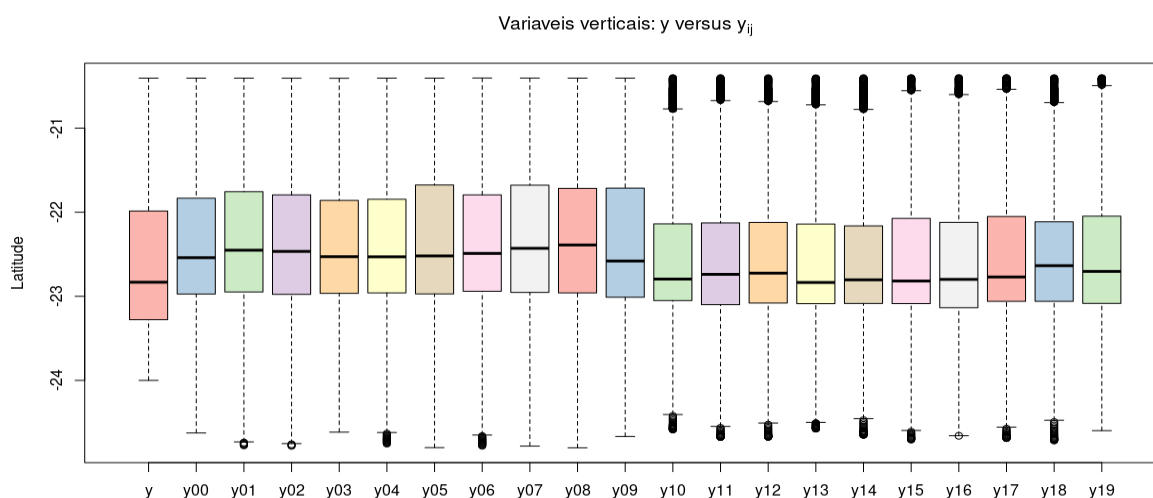


Figura 7. Gráfico boxplot das variáveis verticais (latitude): y (variável resposta) e y_{ij} (variáveis preditoras)

Fonte. Resultados originais da pesquisa

Ambos os modelos geraram variáveis (x_{ij} e y_{ij}) com distribuição parecida com a distribuição dos dados observados (x e y), possuindo uma leve tendência de deslocar a mediana para valores maiores. Os dados de latitude (y e y_{ij}) indicam ter uma distribuição simétrica, enquanto os dados de longitude (x e x_{ij}) possuem uma assimetria positiva perceptível.

As simulações com o modelo Mercator ($i=1$) possuem maior variância na longitude, do que as simulações com o modelo HYCOM ($i=0$). Curiosamente, esse padrão se inverte na distribuição dos dados de latitude. Essa relação sugere que as partículas simuladas com Mercator tendem a ter maior dispersão horizontal e, portanto, mais susceptíveis à meandros e vórtices.

Modelos de Machine Learning

As médias das variáveis preditoras horizontais (\underline{x}_{ij}) e verticais (\underline{y}_{ij}) mostraram-se inadequadas para a determinação das variáveis resposta, com valores de erro muito altos. No entanto, os resultados servem de parâmetro de referência para os modelos de Machine Learning sugeridos. A Figura 8 mostra o resultado da média das variáveis preditoras para cada partícula sobre os valores observados.

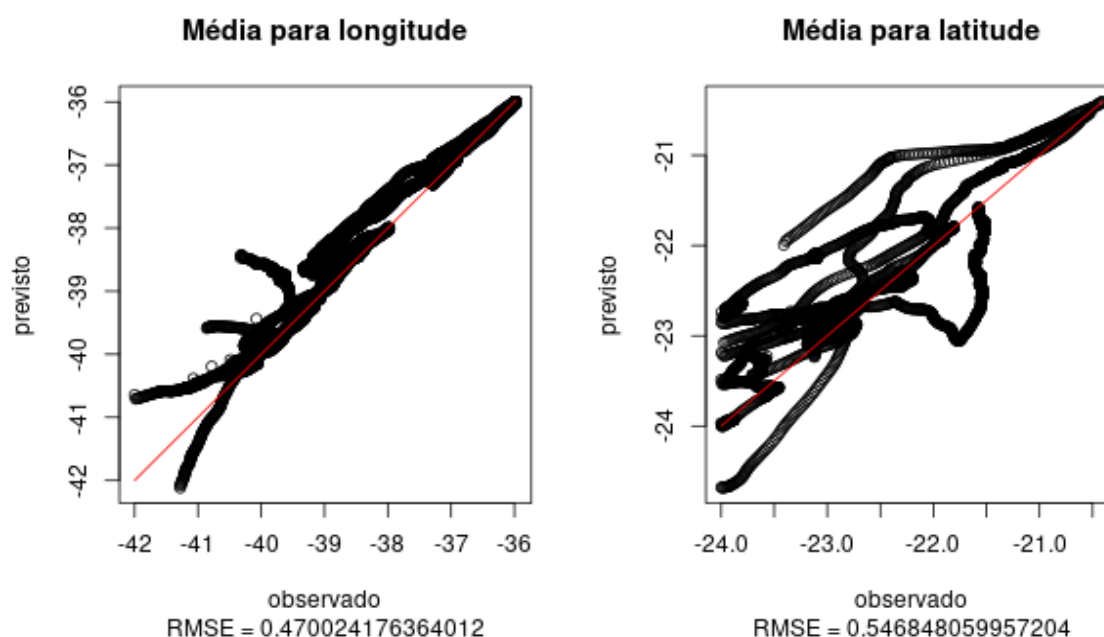


Figura 8. Projeção dos dados previstos (média) pelos dados observados para a longitude e latitude

Fonte: Resultados originais da pesquisa

O Modelo de Regressão Linear [MRL] mostrou resultados melhores que a média, embora a Figura 9 mostre pouca aderência entre os valores previstos e os observados.

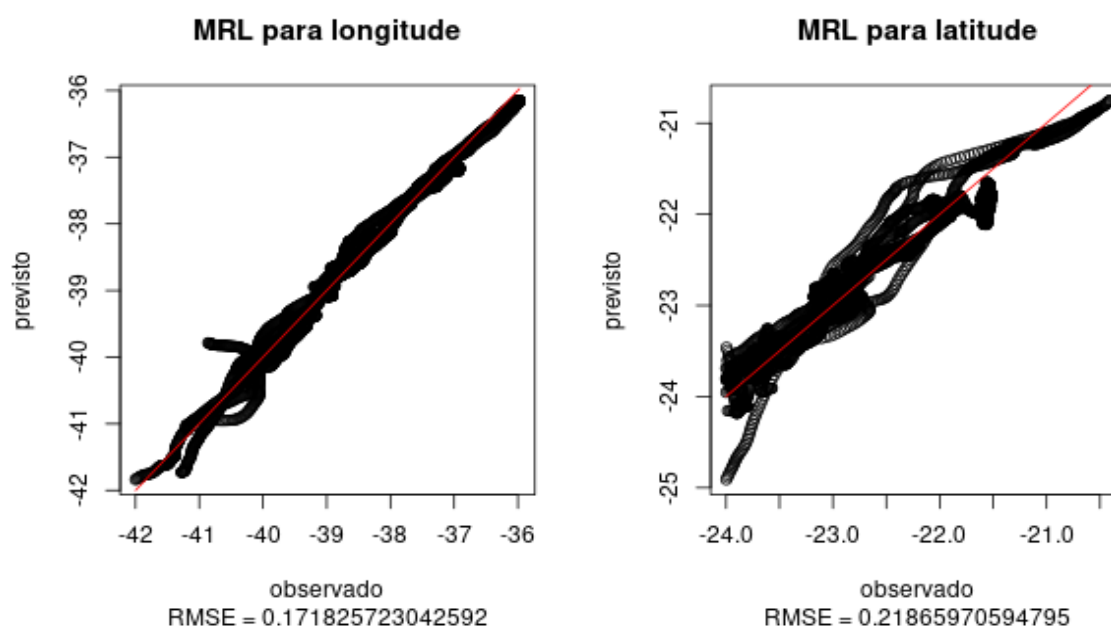


Figura 9. Projeção dos dados previstos (MRL) pelos dados observados para a longitude e latitude

Fonte: Resultados originais da pesquisa

Os modelos para longitude e latitude passaram no Teste-F com $p\text{-value} < 0,05$. Devido à grande correlação entre as variáveis preditoras, o processo de stepwise mostrou algumas variáveis com baixa significância estatística e multicolinearidade, sendo excluídas da fórmula final. No entanto, o teste de Shapiro-Francia indicou pouca aderência dos resíduos à Normal ($p\text{-valor} < 0,05$), mostrando que a relação entre as variáveis preditoras e os observados é não-linear.

A transformação de Box-Cox sugerida por Yeo e Johnson (2000), não foi o suficiente para alcançar uma melhora significativa do modelo (MRL-BC). A aderência entre os valores previstos e os observados se manteve baixa e o RMSE se manteve na ordem de grandeza, como mostrado na Figura 10.




Figura 10. Projeção dos dados previstos (MRL-BC) pelos dados observados para a longitude e latitude

Fonte: Resultados originais da pesquisa

Apesar dos modelos MRL-BC para longitude e latitude terem passado nos testes F e T durante o processo de stepwise, o teste de Shapiro-Francia ainda acusou pouca aderência entre os resíduos e a curva Normal ($p\text{-valor} < 0,05$). Por outro lado, o modelo “Random Forest” mostrou grande aderência entre os valores previstos e os observados, dentro do grupo de teste, conforme mostrado na Figura 11.




Figura 11. Projeção dos dados previstos (RF) pelos dados observados para a longitude e latitude

Fonte: Resultados originais da pesquisa

O modelo de XG Boosting também apresentou grande aderência entre os valores previstos e os observados, dentro do grupo de teste. No entanto, o RMSE encontrado é um pouco maior que o modelo anterior tanto para longitude como para latitude, conforme ilustrado na Figura 12.

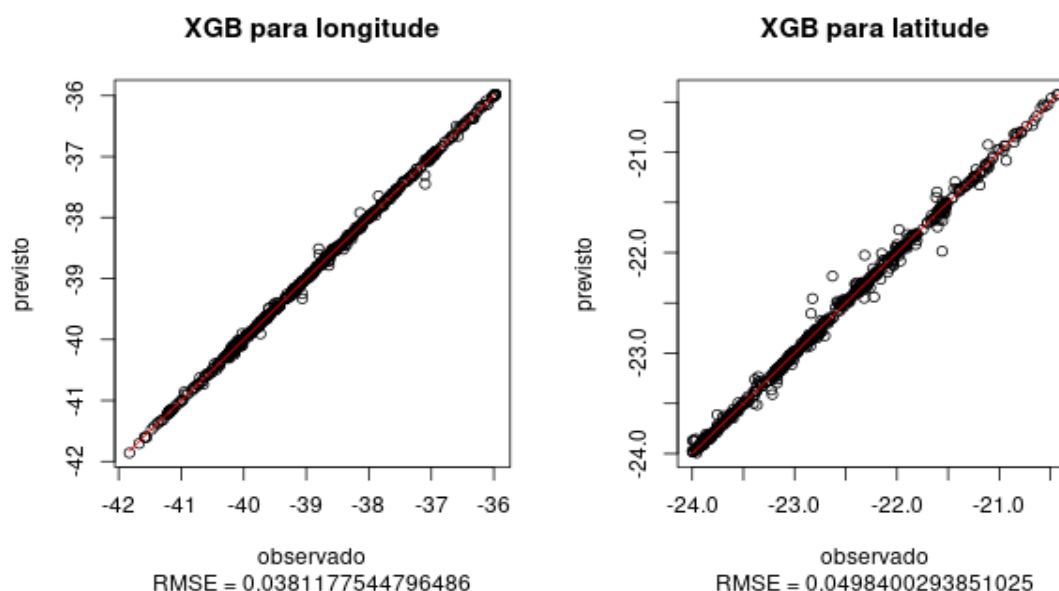


Figura 12. Projeção dos dados previstos (XGB) pelos dados observados para a longitude e latitude

Fonte: Resultados originais da pesquisa

Foram realizados testes com diferentes arquiteturas de Rede Neural Multicamadas, conforme demonstrado na Tabela 3. O resultado mais promissor foi com 10 neurônios na primeira camada e 5 neurônios na segunda camada escondida.

Tabela 3. Testes de arquitetura de Rede Neural Multicamadas

Arquitetura		Longitude		Latitude	
1ª camada	2ª camada	MAE	RMSE	MAE	RMSE
5	3	0,0696	0,0882	0,0673	0,0846
7	3	0,0747	0,0987	0,0537	0,0702
10	5	0,0519	0,0702	0,0343	0,0480

Fonte: Resultados originais da pesquisa

A Figura 13 mostra o ajuste entre os valores preditos e observados com a RNM de melhor resultado.




Figura 13. Projeção dos dados previstos (RNM) pelos dados observados para a longitude e latitude

Fonte: Resultados originais da pesquisa

Por fim, a Tabela 4 resume os resultados dos modelos de Machine Learning e o benchmark para a longitude e latitude, respectivamente.

Tabela 4. Erros dos modelos de Machine Learning

	Longitude		Latitude	
	MAE	RMSE	MAE	RMSE
Média ¹	0,3332201	0,4700242	0,3895752	0,5468481
MRL ²	0,1235711	0,1718257	0,1726048	0,2186597
MRL-BC ²	0,1076064	0,1525089	0,1706372	0,2113726
RF	0,0092262	0,0152116	0,0133759	0,0248463
XGB	0,0201842	0,0381177	0,0257174	0,0498401
RNM	0,0519307	0,0701724	0,0342771	0,0480565

Fonte: Resultados originais da pesquisa

Nota: ⁽¹⁾ Benchmark; ⁽²⁾ Modelos com resíduos sem aderência à Normal.

Os menores valores de MAE e RMSE são do modelo Random Forest [RF], portanto, neste caso, considerado o mais aceitável modelo para ajustar as coordenadas das trajetórias simuladas. Posteriormente, seguem os modelos de XG Boosting e Rede Neurais Artificiais Multicamadas.

Considerações Finais

Diante do exposto, fica evidenciada a viabilidade de utilização de modelos de Machine Learning para o aprimoramento de simulações de deriva em casos de SAR na Baía de Campos. Dentre os modelos analisados, os resultados mais promissores foram do modelo Random Forest. A metodologia pode ser expandida para outras regiões da costa, desde que haja um banco de dados com observações de derivadores para as áreas de interesse. Nesse caso, uma nova análise de Machine Learning deve ser realizada para verificar o modelo indicado. Sugere-se a utilização de modelos atmosféricos e hidrodinâmicos regionais, com maior resolução espacial, a fim de aumentar a precisão das simulações das trajetórias realizadas pelo modelo OpenDrift. Também é possível que outras arquiteturas de rede neurais (ou mesmo outras famílias de algoritmos), aqui não testadas, possam ser mais eficientes nesse caso, sendo interessante a investigação em trabalhos futuros; além do teste de esforço computacional, para fins de comparação dos métodos e ferramentas.

Referências

Allen, Art and Jeffery V Plourde, 1999: Review of leeway: field experiments and implementation, US Coast Guard tech report CG-D-08-99.

Anarumo, J.; Miles, T.; Roarty, H.; Kohut, J.; Beird, N. An open-source software application for drifter trajectory prediction in the mid-atlantic bight. In: Global Oceans 2020: Singapore–Us Gulf Coast. Ieee, 2020. P. 1-8.

Assad, L. P. F.; Mano, M. F.; Decco, H. T.; Torres Júnior, A. R.; Landau, L. Noções básicas de modelagem hidrodinâmica computacional e de dispersão de poluentes. 1 Ed. Rio de Janeiro: Coppe, 2009. 126p. Isbn 978-85-285-0139-1.

Breivik, Ø.; Allen, A. A. An operational search and rescue model for the norwegian sea and the north sea. Journal of marine systems, V. 69, N. 1-2, P. 99-113, 2008.

Bueno, L. F. et al. Um sistema operacional de previsão oceânica para a costa leste-sudeste brasileira. in: simpósio sobre ondas, marés, engenharia oceânica e oceanografia por satélite, XIV, 2021, Anais de resumos. Arraial do Cabo, 2022. p. 79-82.

Calado, L., 2001. Dinâmica da formação dos meandros e vórtices da corrente do Brasil ao largo do sudeste brasileiro. Dissertação de Mestrado, Universidade De São Paulo, São Paulo.

Castro, B. M., 1996. Correntes e massas de água da plataforma continental norte de São Paulo. tese de livre docência, Instituto Oceanográfico da Universidade de São Paulo, São Paulo.

COPERNICUS - E.U. Copernicus Marine Service Information. Global Ocean 1/12° Physics Analysis and Forecast updated Daily. Disponível em:
<<https://resources.marine.copernicus.eu/product-detail>. Acesso em: 15 jan. 2022.

Copernicus Marine In Situ Tac (2020). For Global Ocean-Delayed Mode in-situ Observations of surface (drifters and HFR) and sub-surface (vessel-mounted ADCPs) water velocity. Quality Information Document (QUID). CMEMS-INS-QUID-013-044. Disponível em:
<https://doi.org/10.13155/41256>. Acesso em: 08 fev 2022.

CORIOLIS - Coriolis Operational Oceanography. Data selection. Disponível em:
<<https://www.coriolis.eu.org/Data-Products/Data-selection>>. Acesso em: 15 dez. 2021.

Dagestad, K.-F., Röhrs, J., Breivik, Ø., and Ådlandsvik, B.: OpenDrift v1.0: A generic framework for trajectory modelling, *Geosci. Model Dev.*, 11, 1405-1420,
<https://doi.org/10.5194/gmd-11-1405-2018>, 2018.

De Dominicis, M.; Bruciaferri, D.; Gerin, R.; Pinardi, N.; Poulain, P. M.; Garreau, P.; Zodiatis, G.; Perivoliotis, L.; Fazioli, L.; Sorgente, R.; Manganiello, C. A Multi-model assessment of the impact of currents, waves and wind in modelling surface drifters and oil spill. *Deep Sea Research Part II: Topical Studies in Oceanography*, V. 133, P. 21-38, 2016.

DPC - Diretoria de Portos e Costas. Acidentes de Navegação. Inquéritos Administrativos sobre Acidentes e Fatos da Navegação (IAFN). Quadros Estatísticos de IAFNs. 21 de abr. de 2022.

Fávero, L. P.; Almeida, J. E. F. 2011. O comportamento dos índices de ações em países emergentes: uma análise com dados em painel e modelos hierárquicos. *Revista Brasileira De Estatística*, V. 72, P. 97-137.

Gelman, A. 2006. Multilevel (Hierarchical) Modeling: What it can and cannot do. *Technometrics*, 48(3): 432-435.

GFS: NOAA National Centers for Environmental Prediction (NCEP). 2011. NOAA/NCEP Global Forecast System (GFS) Atmospheric Model. Distributed by the Pacific Islands Ocean Observing System (PacIOOS). http://pacioos.org/metadata/ncep_global.html. Acesso em: 15 jan. 2022.

Godoi, S. S. 2005. Dinâmica quase-geostrófica do sistema Corrente do Brasil no embaçamento de São Paulo (23,5°-27°s). Tese de Doutorado. Instituto Oceanográfico – Usp, São Paulo. 133p

Hole, L.R.; Dagestad, K.-F.; Röhrs, J.; Wettre, C.; Kourafalou, V.H.; Androulidakis, Y.; Kang, H.; Le Hénaff, M.; Garcia-Pineda, O. The deepwater horizon oil slick: simulations of HYCOM - HYbrid Coordinate Ocean Model. *HYCOM Overview*. Disponível em:
<https://www.hycom.org/>. Acesso em: 24 mar. 2022.

Lemos, C. F.; Calbete, N. O. 1996, "Sistemas frontais que atuaram no litoral do Brasil (Período 1987-1995)", *Climanálise Especial*, 11, Pp 131-134.

Ličer M.; Estival S.; Reyes-Suarez C.; Deponte D.; Fettich A. Lagrangian modelling of a person lost at sea during the adriatic scirocco storm of 29 October 2018. *Natural Hazards And Earth System Sciences*, V. 20, N. 8, P. 2335-2349, 2020.

Lima, J. A. M., 1997: Oceanic circulation on the Brazil Current shelf break and slope at 22°S. Tese de Doutorado, University of New South Wales, New South Wales, 144 pp.

Lumpkin, R.; Özgökmen, T.; Centurioni, L. Advances in the application of surface drifters. Annual Review Of Marine Science, V. 9, P. 59-81, 2017.

Mano, M. F. 2007. Assimilação de dados em modelo oceanográfico da bacia sudoeste do atlântico para reproduzir e prever circulação superficial e feições de meso-escala. Tese (Doutorado em Engenharia Civil), Programas de Pós-graduação de Engenharia, Universidade Federal do Rio de Janeiro, Rio de Janeiro.

Natis, L. 2000. Modelos Lineares Hierárquicos. Instituto de Matemática e Estatística, Universidade De São Paulo, São Paulo. Dissertação de Mestrado.

Rezende Jhm De. 2003. Intrusões da Água Central do Atlântico Sul na plataforma continental sudeste durante o verão. Tese de Doutorado. Universidade de São Paulo, Instituto Oceanográfico, 120 P. RiverFront Effects and Oil Droplet Size Distribution. J. Mar. Sci. Eng. 2019, 7, 329.

Rodrigues, R.R.; Lorenzzetti, J. A. 2001, "A numerical study of the effects of bottom topography and coastline geometry on the southeast brazilian coastal upwelling." Continental Shelf Research, Dorchester, 21, N. 4, Pp. 371-394.

Royston, P. (1993): A pocket-calculator algorithm for the Shapiro-Francia test for non-normality: an application to medicine. Statistics in Medicine, 12, 181–184.

SALVAMAR BRASIL. Comando de Operações Navais. SALVAMAR BRASIL: Histórico. Disponível em: <<https://www.marinha.mil.br/salvamarbrasil/content/historico>>. Acesso em: 07 de fev de 2022.

Silveira I. C. A. 2007. O Sistema Corrente do Brasil na Bacia de Campos, RJ. Tese (Livre Docência), Instituto Oceanográfico, Universidade de São Paulo. São Paulo.

Stech, J. L.; Lorenzzetti, J. A. 1992, "The Response Of The Southbrazil Bight To The Passage Of Wintertime Cold Fronts." J. Geophysical Research, 97 (66), Pp 9507-9520.

Smith, W. H. F., and D. T. Sandwell, Global seafloor topography from satellite altimetry and ship depth soundings, Science, v. 277, p. 1957-1962, 26 Sept., 1997. Disponível em: https://topex.ucsd.edu/cgi-bin/get_data.cgi. Acesso em: 10 jan 2022.

Sutherland, G., Soontiens, N., Davidson, F., Smith, G. C., Bernier, N., Blanken, H., Schillinger, D.; Marcotte, G.; Röhrs, J.; Dagestad, K. F.; Christensen, K. H.; Breivik, O. Evaluating The Leeway Coefficient For Different Ocean Drifters Using Operational Models. Arxiv Preprint Arxiv:2005.09527, 2020.

Van Sebille, E.; Griffies, S. M.; Abernathey, R.; Adams, T. P.; Berloff, P.; Biastoch, A.; Blanke, B.; Chassignet, E. P.; Cheng, Y.; Cotter, C. J.; Deleersnijder, E.; Döös, K.; Drake, H. F.; Drijfhout, S.; Gary, S. F.; Heemink, A. W.; Kjellsson, J.; Koszalka, I. M.; Lange, M.; Lique, C.; Macgilchrist, G. A.; Marsh, R.; Adame, C. G. M.; Mcadam, R.; Nencioli, F.; Paris, C B.; Piggott, M. D.; Polton, J. A.; Rühls, S.; Shah, S. H. A. M.; Thomas, M. D.; Wang, J.; Wolfram, P. J.; Zanna, L.; Zika, J. D. Lagrangian Ocean Analysis: Fundamentals and Practices. Ocean Modelling, V. 121, P. 49-75, 2018.

Venables, W. N. and Ripley, B. D. (2002) Modern applied statistics with S. New York: Springer (4th ed).

Viana, A. R., J. C. Faugeres, R. O. Kowsmann, J. A. M. Lima, L. F. G. Caddah, & J. G. Rizzo, 1998: Hydrology, morphology and sedimentology of the Campos continental margin, offshore Brazil. Sement. Geol., 115, 133–157.

Yeo, I. and Johnson, R. (2000) A new family of power transformations to improve normality or symmetry. Biometrika, 87, 954-959.

Apêndice A

Resultados do modelo lagrangeano de partículas: Opendrft

As Figuras A-1 a A-13 mostram o resultados da simulação de dez partículas, para cada derivador, utilizando o modelo lagrangeano Opendrft com as forçantes ambientais dos modelos HYCOM/NCODA + GFS e Mercator + GFS.




Figura A-1. Simulações com Opendrft para o derivador 1501559. (a)HYCOM/NCODA (b)Mercator

Fonte: Resultados originais da pesquisa

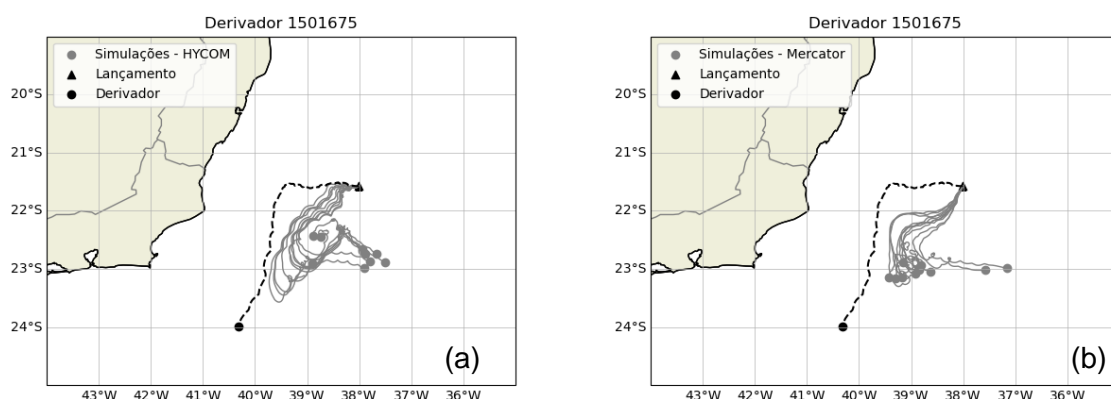


Figura A-2. Simulações com Opendrft para o derivador 1501675. (a)HYCOM/NCODA (b)Mercator.Fonte: Resultados originais da pesquisa




Figura A-3. Simulações com Opendrft para o derivador 1501676. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa




Figura A-4. Simulações com Opendrft para o derivador 1601695. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa




Figura A-5. Simulações com Opendrft para o derivador 1701516. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa




Figura A-6. Simulações com Opendrft para o derivador 1701643. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa




Figura A-7. Simulações com Opendrft para o derivador 1701647. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa

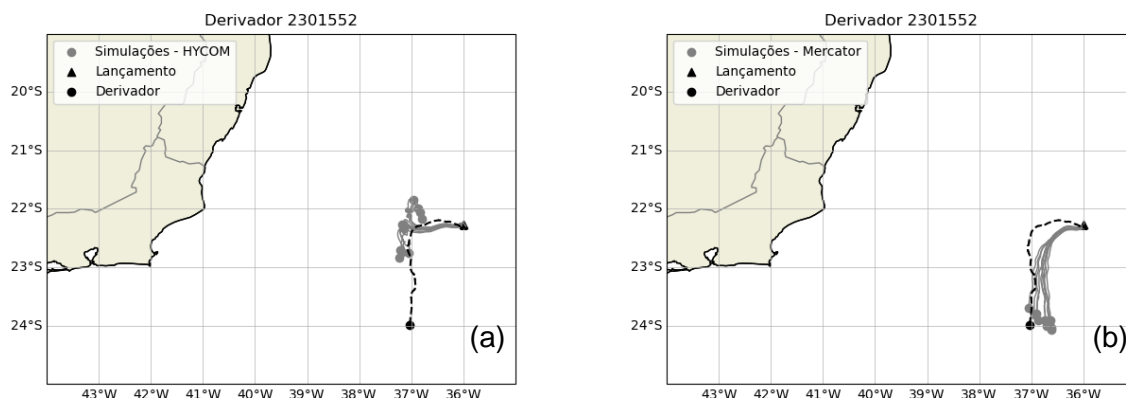


Figura A-8. Simulações com Opendrft para o derivador 2301552. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa




Figura A-9. Simulações com Opendrift para o derivador 3100865. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa

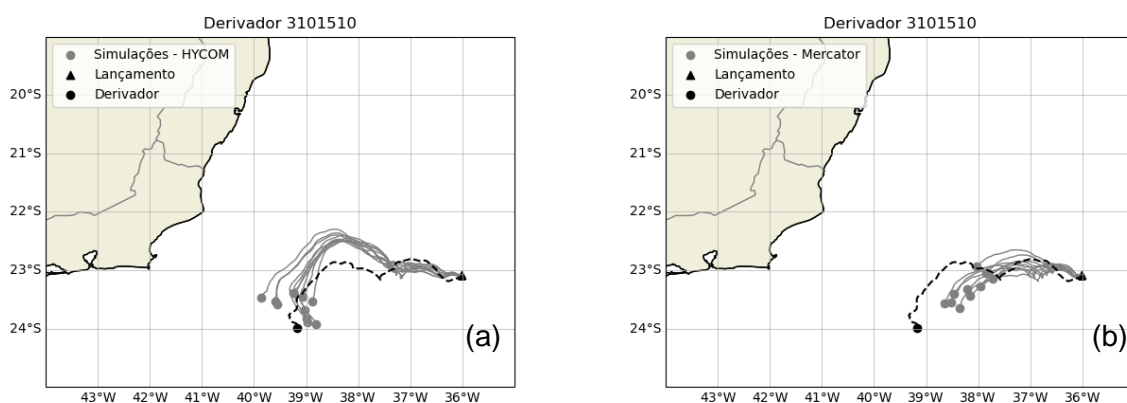


Figura A-10. Simulações com Opendrift para o derivador 3101510. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa

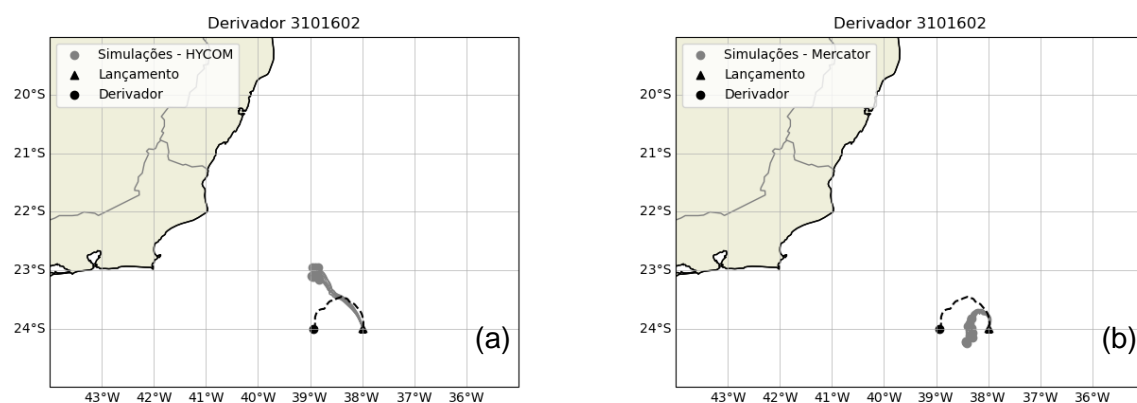


Figura A-11. Simulações com Opendrift para o derivador 3101502. (a)HYCOM/NCODA (b)Mercator.

Fonte: Resultados originais da pesquisa

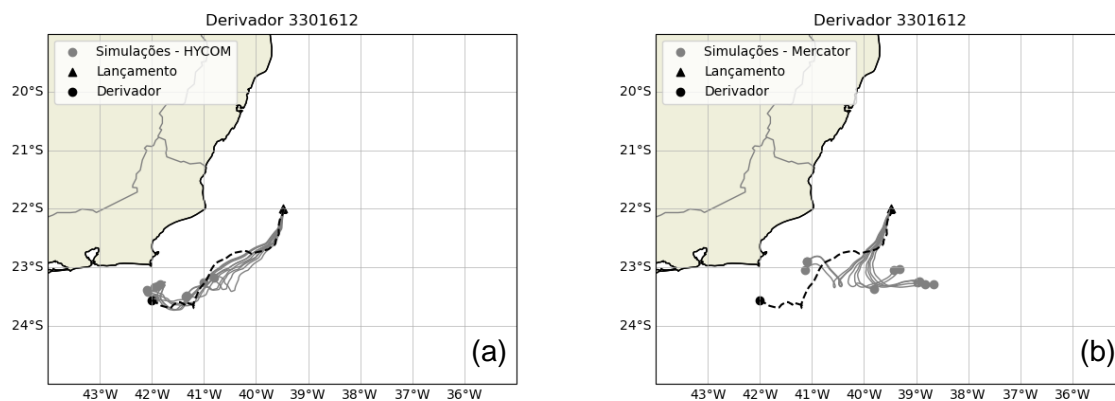


Figura A-12. Simulações com Opendrift para o derivador 3301612. (a)HYCOM/NCODA
(b)Mercator.

Fonte: Resultados originais da pesquisa




Figura A-13. Simulações com Opendrift para o derivador 6202622. (a)HYCOM/NCODA
(b)Mercator.

Fonte: Resultados originais da pesquisa